# Statistiques et probabilités — exemples progressifs

Chaque chapitre correspond à un niveau ou à une étape. Choisissez son titre dans le sommaire pour y accéder directement.

# Sommaire


**1 - Collège** ..... **3**
1.1 - Moyenne, médiane, étendue, quartiles ..... 3
1.2 - Proportionnalité ..... 3
1.3 - Pourcentages ..... 4
1.4 - Échelles et vitesses ..... 4
**2 - Lycée** ..... **5**
2.1 - Notations du dénombrement ..... 5
2.2 - Probabilité et espérance ..... 5
2.3 - Arbre de probabilités ..... 5
2.4 - Diagrammes statistiques ..... 6
2.5 - Lois du lycée, calculées ..... 7
2.6 - Loi de probabilité ..... 8
2.7 - Variance, écart type, covariance ..... 8
2.8 - Lois en notation ..... 8
2.9 - répartition et densité ..... 8
2.10 - Espérances et écarts types, en tableau ..... 9
2.11 - Échantillonnage et concentration ..... 9
2.12 - Estimer une proportion : l'intervalle de confiance ..... 9
**3 - Enseignement supérieur** ..... **10**
3.1 - Lois continues du supérieur, calculées ..... 10
3.2 - La loi des grands nombres, illustrée par une boucle ..... 10
3.3 - Le théorème central limite, en un cadre ..... 10
3.4 - Les lois à densité ..... 11
3.5 - L'ajustement par moindres carrés ..... 11
3.6 - La loi normale ..... 11
3.7 - Le théorème central limite ..... 12
3.8 - Statistique inférentielle ..... 12
3.8.1 - Estimer une moyenne ..... 12
3.8.2 - Tester une valeur de référence ..... 13
3.8.3 - Comparer deux moyennes ..... 13
3.8.4 - Un dé est-il équilibré ? ..... 14
3.8.5 - Deux caractères sont-ils indépendants ? ..... 15
3.9 - Analyse de données : la classification ..... 16
3.9.1 - Les k-moyennes ..... 16
3.9.2 - La classification ascendante hiérarchique ..... 16
3.10 - Autant de dés que l'on veut ..... 17

# 1 - Collège

## 1.1 - Moyenne, médiane, étendue, quartiles

$\bar{x} = \frac{12+15+9+14}{4} = \frac{50}{4} = 12{,}5.$

La moyenne pondérée vaut $\bar{x} = \frac{8\times 2+12\times 5+15\times 3}{10} = \frac{121}{10} = 12{,}1.$

On range la série dans l'ordre croissant : 9 ; 12 ; 14 ; 15 (4 valeurs).
L'effectif est pair : la médiane est la demi-somme des 2e et 3e valeurs, $m = \frac{12+14}{2} = 13.$

On range la série dans l'ordre croissant : 3 ; 5 ; 7 ; 9 ; 11 (5 valeurs).
L'effectif est impair : la médiane est la 3e valeur, $m = 7.$

L'étendue est l'écart entre la plus grande et la plus petite valeur : $e = 15 - 9 = 6.$

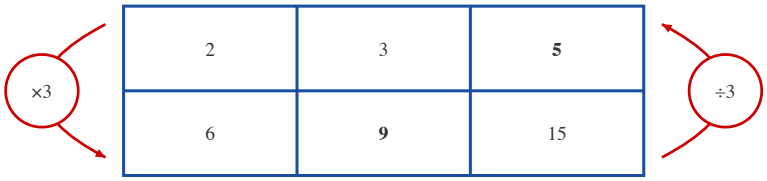
Série rangée : 2 ; 4 ; 5 ; 7 ; 8 ; 10 ; 12 ; 15 (8 valeurs).
Le premier quartile est la 2e valeur ($\lceil n/4 \rceil$) : $Q_1 = 4$ ; le troisième est la 6e ($\lceil 3n/4 \rceil$) : $Q_3 = 10.$

## 1.2 - Proportionnalité

On cherche $x$ tel que $\frac{3}{5} = \frac{12}{x}$. Le produit en croix donne $3 \times x = 5 \times 12$, d'où $x = \frac{5\times 12}{3} = 20.$

On compare les rapports colonne par colonne : $\frac{6}{2} = 3$, $\frac{9}{3} = 3$, $\frac{15}{5} = 3.$
Tous les rapports sont égaux : le tableau est un tableau de proportionnalité, de coefficient $3$.

On compare les rapports colonne par colonne : $\frac{6}{2} = 3$, $\frac{9}{3} = 3$, $\frac{14}{5} = 2{,}8.$
Les rapports ne sont pas tous égaux : ce n'est pas un tableau de proportionnalité.



## 1.3 - Pourcentages

$30\,\%$ de $250$ : $\frac{30}{100} \times 250 = 75$.

Une augmentation de $5\,\%$ revient à multiplier par $1 + \frac{5}{100} = 1{,}05$. Donc $240 \times 1{,}05 = 252$.

Une diminution de $12\,\%$ revient à multiplier par $1 - \frac{12}{100} = 0{,}88$. Donc $60 \times 0{,}88 = 52{,}8$.

$t = \frac{\text{valeur finale} - \text{valeur initiale}}{\text{valeur initiale}} \times 100 = \frac{280-250}{250} \times 100 = 12$ : une augmentation de $12\,\%$.

## 1.4 - Échelles et vitesses

L'échelle est le rapport $\frac{\text{distance sur le plan}}{\text{distance réelle}}$, les deux dans la même unité : $\frac{2\text{ cm}}{5000\text{ cm}} = \frac{1}{2500}$ — un centimètre sur le plan représente $2500$ cm dans la réalité.

On convertit la durée : $2\text{ h }30\text{ min} = 2{,}5\text{ h}$. La vitesse moyenne vaut $v = \frac{d}{t}$.
Ici, $v = \frac{150\text{ km}}{2{,}5\text{ h}} = 60\text{ km/h}$.

On convertit la durée : $1\text{ h }45\text{ min} = 1{,}75\text{ h}$. La distance vaut $d = v \times t$.
Ici, $d = 80 \times 1{,}75 = 140\text{ km}$.

La durée vaut $t = \frac{d}{v}$.
Ici, $t = \frac{210}{60} = 3{,}5\text{ h} = 3\text{ h }30\text{ min}$.

# 2 - Lycée

## 2.1 - Notations du dénombrement

Le coefficient binomial est $\binom{n}{k}$ ; à un seul argument, $C\left(t\right)$ reste une fonction ordinaire.
L'arrangement est $A_n^k$, la factorielle $n!$.
La règle de Pascal et le binôme :

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$$

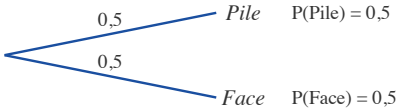
$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}$$

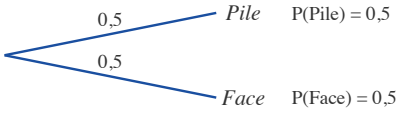
## 2.2 - Probabilité et espérance

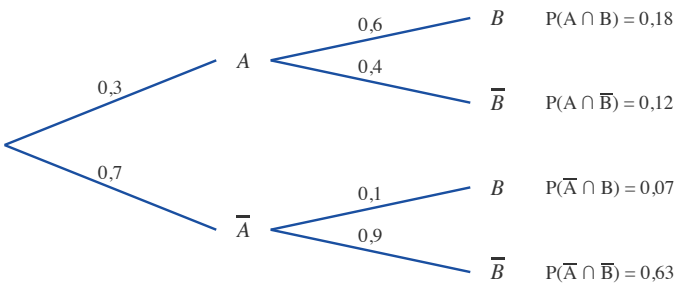
$\mathbb{P}(A)$ est une probabilité, $\mathbb{E}(X)$ une espérance ; le conditionnement se dit « sachant » : $\mathbb{P}(A \mid B)$.
$\mathbb{P}(A) = \mathbb{P}(A \mid B)\mathbb{P}(B) + \mathbb{P}(A \mid \overline{B})\mathbb{P}(\overline{B})$
$\mathbb{E}(X) = \sum_{k=1}^{n} k\mathbb{P}(X = k)$

## 2.3 - Arbre de probabilités

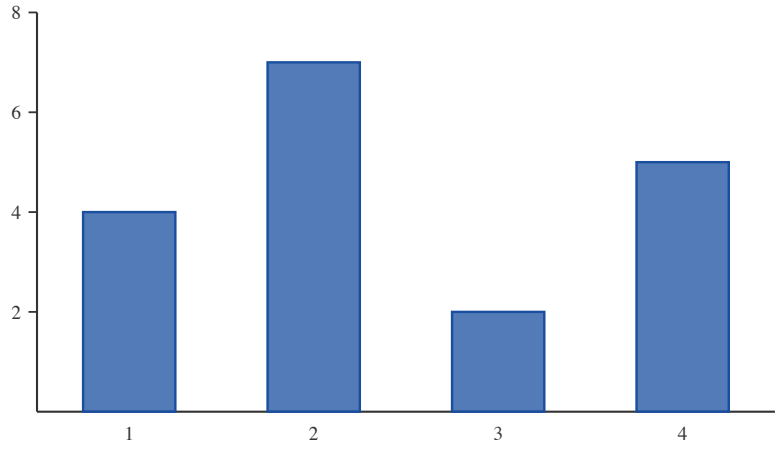
Un nœud à branche unique reçoit son complément automatiquement, le produit de chaque chemin s'imprimant à la feuille :

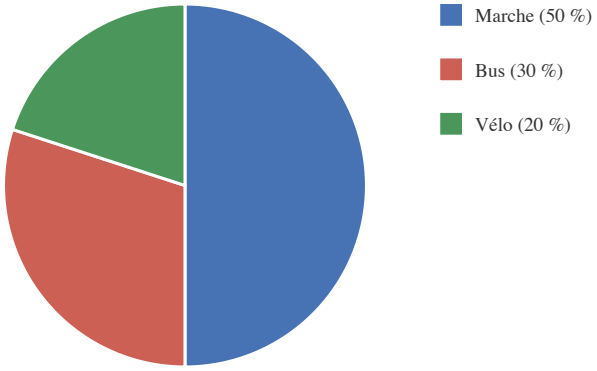


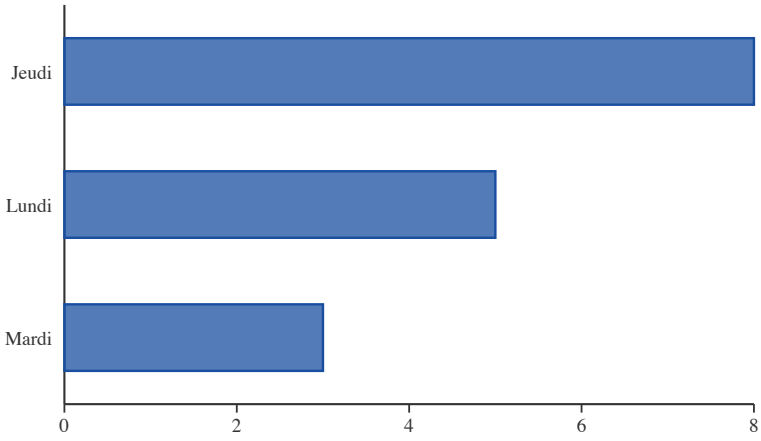



## 2.4 - Diagrammes statistiques

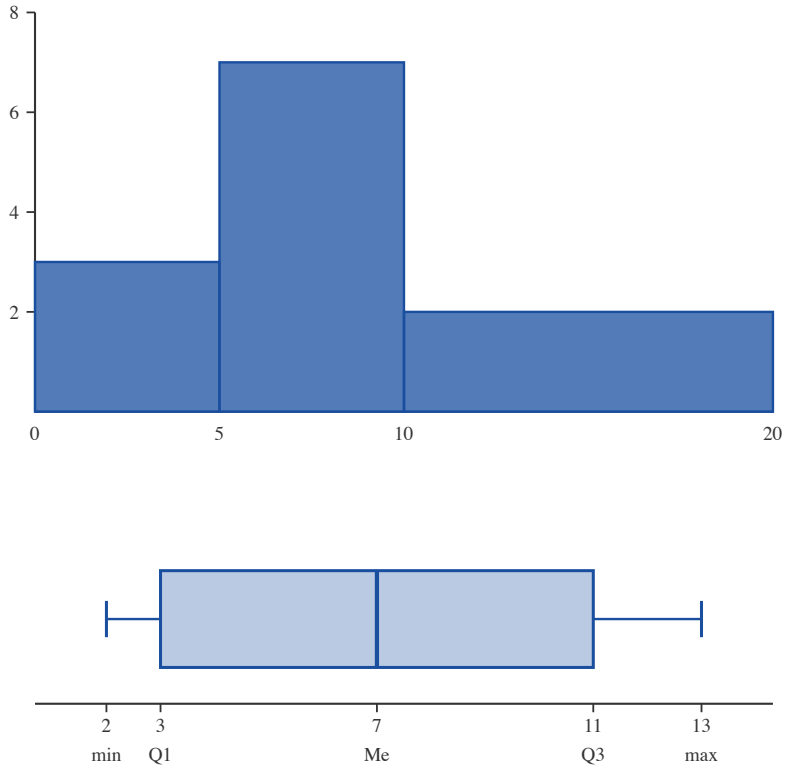


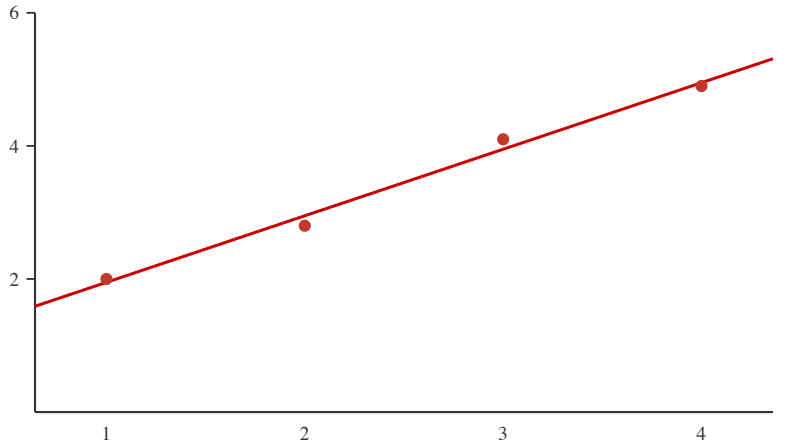

Les mêmes données, déclarées une fois et réutilisées par leur nom :



Un histogramme à classes, de bornes et d'effectifs déclarés en toutes lettres :




Un nuage de points avec sa droite d'ajustement :




## 2.5 - Lois du lycée, calculées

$P(X \leqslant 1{,}96) \approx 0{,}975$
$P(X \geqslant 3) \approx 0{,}945$
$P(X = 2) \approx 0{,}251$
$x_{0{,}95} \approx 1{,}645$
$E(X) \approx 1$
$\sigma(X) \approx 2$

## 2.6 - Loi de probabilité

Les valeurs et les probabilités se donnent en deux lignes ; le tableau se dresse tout seul et la somme des probabilités est vérifiée — une loi qui ne totalise pas 1 est refusée avec le total fautif.

| $x_i$ | 1 | 2 | 3 |
|---|---|---|---|
| $P(X = x_i)$ | $\frac{1}{6}$ | $\frac{1}{3}$ | $\frac{1}{2}$ |

$E(X) = \sum x_i P(X = x_i)$.
Ici, $E(X) = \frac{7}{3} \approx 2{,}3333$.
$V(X) = E(X^2) - E(X)^2$.
Ici, $V(X) = \frac{5}{9} \approx 0{,}5556$.
$\sigma(X) = \sqrt{V(X)}$.
Ici, $\sigma(X) = \frac{\sqrt{5}}{3} \approx 0{,}7454$.

## 2.7 - Variance, écart type, covariance

$\mathrm{Var}(X)$ est la variance, $\sigma(X)$ l'écart type,
$\mathrm{Cov}\left(X\,,\,Y\right)$ la covariance ; l'identité de König-Huygens :
$\mathrm{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$
Et sur les séries statistiques, les trois se calculent :
La variance vaut $V = \frac{1}{n}\sum (x_i - \bar{x})^2$.
Ici, $\bar{x} = 12{,}5$ puis $V = 5{,}25$.
L'écart type vaut $\sigma = \sqrt{V}$.
Ici, $\bar{x} = 12{,}5$, $V = 5{,}25$ puis $\sigma = \sqrt{5{,}25} \approx 2{,}291$.
La variance vaut $V = \frac{1}{N}\sum n_i (x_i - \bar{x})^2$.
Ici, $\bar{x} = 12{,}1$ puis $V = 5{,}89$.
La covariance vaut $\mathrm{cov}(x, y) = \frac{1}{n}\sum (x_i - \bar{x})(y_i - \bar{y})$.
Ici, $\bar{x} = 2$, $\bar{y} \approx 4{,}333$ puis $\mathrm{cov}(x, y) \approx 1{,}667$.

## 2.8 - Lois en notation

$X$ suit $\mathcal{N}\left(0\,,\,1^2\right)$, la normale centrée réduite ; $N$ suit
$\mathcal{P}\left(\lambda\right)$ avec $\mathbb{P}(N = k) = e^{-\lambda}\frac{\lambda^k}{k}!$ ;
$S$ suit $\mathcal{B}\left(n\,,\,p\right)$ avec $\mathbb{E}(S) = np$.

## 2.9 - répartition et densité

$F_X\left(x\right) = \mathbb{P}(X \leqslant x)$ et, pour une loi continue,
$F_X\left(x\right) = \int_{-\infty}^{x} f_X\left(t\right)\,\mathrm{d}t$.

## 2.10 - Espérances et écarts types, en tableau

| Loi | Espérance | Écart-type |
|---|---|---|
| binomiale(n, p) | $np$ | $\sqrt{np(1-p)}$ |
| poisson(lambda) | $\lambda$ | $\sqrt{\lambda}$ |
| exponentielle(lambda) | $\frac{1}{\lambda}$ | $\frac{1}{\lambda}$ |
| uniforme(a, b) | $\frac{a+b}{2}$ | $\frac{b-a}{\sqrt{12}}$ |

## 2.11 - Échantillonnage et concentration

Au seuil de 95 %, l'intervalle de fluctuation d'une fréquence sur un échantillon de taille $n = 100$, pour une proportion $p = 0{,}3$, est $\left[\, p - \frac{1}{\sqrt{n}} \,;\, p + \frac{1}{\sqrt{n}} \,\right] = [\,0{,}2\,;\,0{,}4\,]$.

Pour une variable aléatoire $X$ d'espérance $\mu = 5$ et de variance $V = 2$, l'inégalité de Bienaymé-Tchebychev donne, pour l'écart $a = 3$ : $P\left(\,|X - \mu| \geqslant a\,\right) \leqslant \frac{V}{a^2} = 0{,}222$.

## 2.12 - Estimer une proportion : l'intervalle de confiance

Sur 100 personnes interrogées, 42 déclarent utiliser les transports en commun. Que dire de la proportion dans toute la population ?

Fréquence observée $f = 0{,}42$ sur $n = 100$. Intervalle de confiance au niveau $95\,\%$ par l'approximation normale $f \pm 1{,}96\sqrt{f(1-f)/n}$ : $[0{,}3233\,;\,0{,}5167]$ ; intervalle exact de Clopper-Pearson : $[0{,}322\,;\,0{,}5229]$.

> *L'intervalle ne contient pas « la » proportion avec une probabilité de 95 % : c'est la méthode qui, répétée sur de nombreux échantillons, produit un intervalle contenant la vraie proportion dans 95 % des cas.*

# 3 - Enseignement supérieur

*Version de démonstration : les saisies sont préremplies pour permettre la lecture intégrale. Les formulaires interactifs d'origine sont conservés dans archives.*

## 3.1 - Lois continues du supérieur, calculées

$P(X \leqslant 0{,}5) \approx 0{,}25$

$P(X \geqslant 1) \approx 0{,}135$

$P(X \leqslant 2) \approx 0{,}963$

$P(X \geqslant 3{,}84) \approx 0{,}05$

$x_{0{,}975} \approx 2{,}262$

## 3.2 - La loi des grands nombres, illustrée par une boucle

La fréquence théorique de pile vaut $0,5$ ; l'écart type de la fréquence observée sur $n$ lancers vaut $\frac{1}{2\sqrt{n}}$ — il fond quand $n$ grandit :

Pour 100 lancers, l'écart type de la fréquence vaut 0,05.
Pour 400 lancers, l'écart type de la fréquence vaut 0,025.
Pour 1600 lancers, l'écart type de la fréquence vaut 0,0125.
Pour 6400 lancers, l'écart type de la fréquence vaut 0,0063.

## 3.3 - Le théorème central limite, en un cadre

**Théorème central limite**

Si $X_1, \ldots, X_n$ sont indépendantes, de même loi, d'espérance

$\mu$ et d'écart type $\sigma$, alors la moyenne centrée réduite

converge en loi vers $\mathcal{N}\left(0\,,\,1^2\right)$ : c'est ce qui fait de la loi

normale la loi des erreurs de mesure.

Le quantile gaussien et son cousin de Student se rejoignent quand le nombre de mesures grandit :

$x_{0,975} \approx 1{,}96$

$x_{0,975} \approx 1{,}984$

## 3.4 - Les lois à densité

Une densité de probabilité est positive et d'intégrale 1 ; l'espérance et la variance s'en déduisent :

$f$ est positive et $\int_0^1 3x^2\,dx = 1$ : c'est une densité de probabilité. L'espérance vaut $E(X) = \int x f(x)\,dx = \dfrac{3}{4}$ et la variance $V(X) = E(X^2) - E(X)^2 = \frac{3}{80}$.

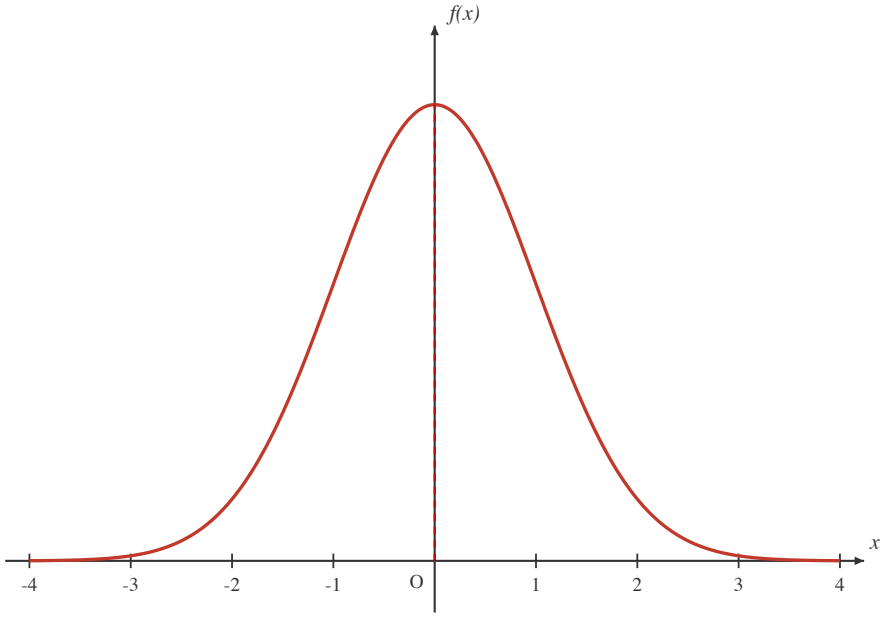
$f$ est positive et $\int_0^\infty e^{-x}\,dx = 1$ : c'est une densité de probabilité. L'espérance vaut $E(X) = \int x f(x)\,dx = 1$ et la variance $V(X) = E(X^2) - E(X)^2 = 1$.

## 3.5 - L'ajustement par moindres carrés

Une décroissance mesurée s'ajuste à un modèle exponentiel — les paramètres sortent avec leur écart :

$N(t) \approx 100{,}1e^{-0{,}4978t}$ $\qquad a \approx 100{,}1\ (u \approx 0{,}33),\ b \approx -0{,}4978\ (u \approx 0{,}0032)$ $\qquad R^2 \approx 0{,}9999$

## 3.6 - La loi normale

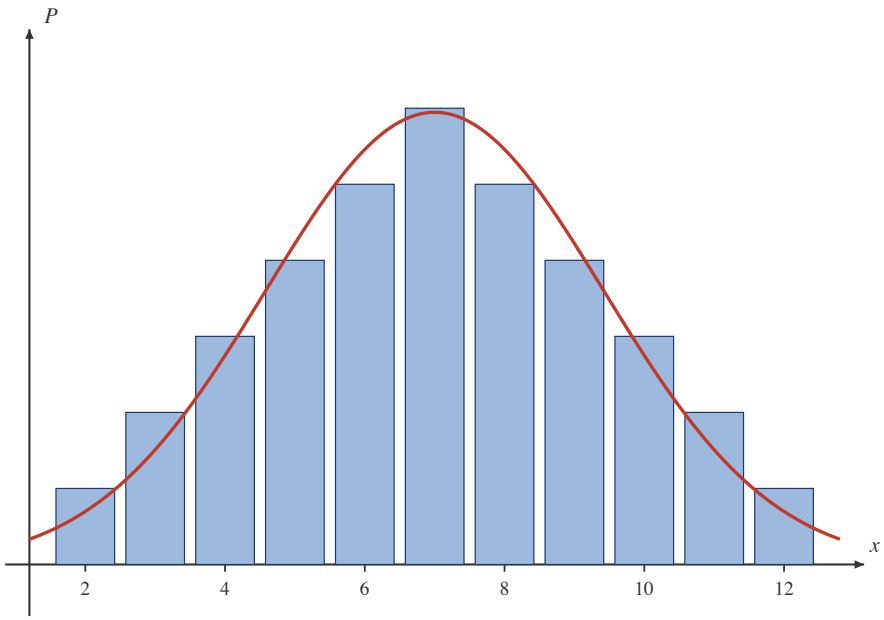


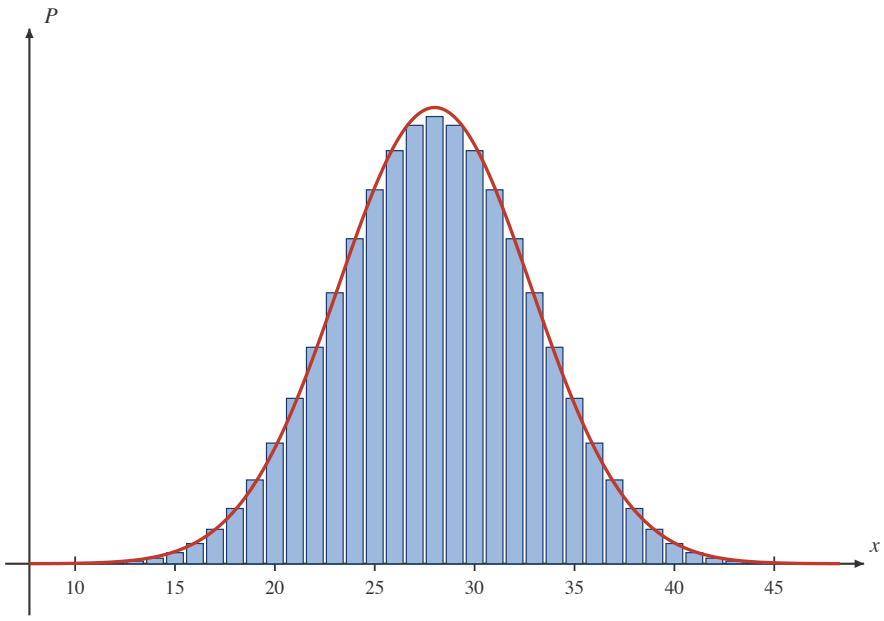

Pour $X \sim \mathcal{N}(0\,;\,1^2)$, $P(-1 \leq X \leq 1) = \int_{-1}^{1} \frac{1}{1\sqrt{2\pi}} e^{-\frac{(x-0)^2}{2\cdot 1^2}}\,dx = \operatorname{erf}\left(\dfrac{\sqrt{2}}{2}\right) \approx 0{,}68269.$

Pour $X \sim \mathcal{N}(0\,;\,1^2)$, $P(-2 \leq X \leq 2) = \int_{-2}^{2} \frac{1}{1\sqrt{2\pi}} e^{-\frac{(x-0)^2}{2\cdot 1^2}}\,dx = \operatorname{erf}\left(\sqrt{2}\right) \approx 0{,}9545.$

## 3.7 - Le théorème central limite

La somme de $n$ dés, recentrée, s'approche de la loi normale — la densité limite se superpose à la loi exacte :




## 3.8 - Statistique inférentielle

Estimer un paramètre, trancher entre deux hypothèses : docdg énonce les hypothèses, donne la statistique, les degrés de liberté et la p-valeur, puis la décision au seuil choisi. La densité de la loi du test montre la zone de rejet et la valeur observée.

### *3.8.1 - Estimer une moyenne*

Quatre mesures d'une même grandeur ; l'écart type de la population est inconnu, d'où la loi de Student.
Intervalle de confiance au niveau $95\,\%$ de la moyenne, par la loi de Student à $3$ degrés de liberté ($t \approx 3{,}182$ ) : $[8{,}29\,;\ 16{,}71]$.
Il est centré sur la moyenne $\bar{x} = 12{,}5$ ; écart type corrigé $s \approx 2{,}646$, effectif $n = 4$.

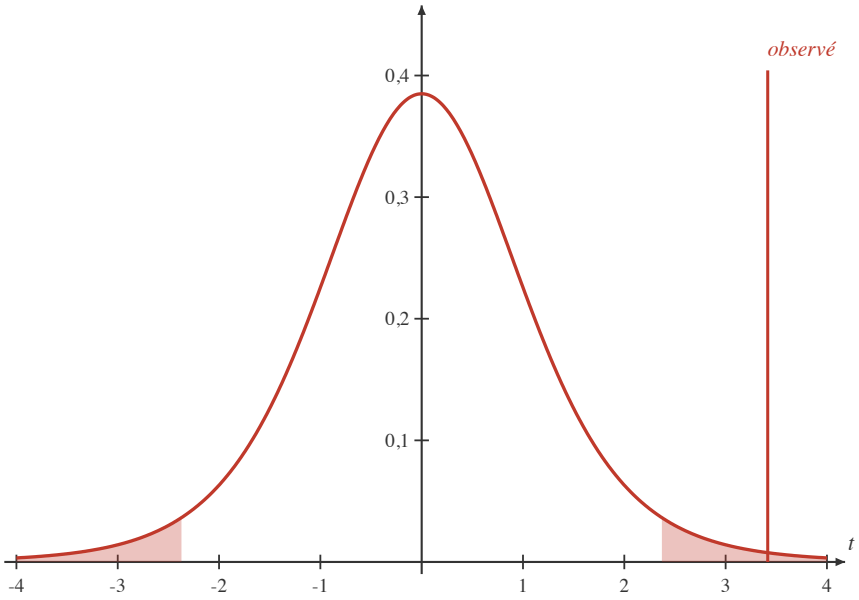
### 3.8.2 - Tester une valeur de référence

Une machine doit remplir des flacons de 12 mL. Sur huit flacons prélevés, le volume est-il conforme ?

Test de Student à un échantillon. $H_0 : \mu = 12$ ; $H_1 : \mu \neq 12$.

Moyenne $\bar{x} = 12{,}38$ sur $n = 8$ valeurs ; statistique $t \approx 3{,}416$, $7$ degrés de liberté ; p-valeur $p \approx 0{,}0112$.

Au seuil de $5\,\%$ : $p < 0{,}05$, on rejette $H_0$ — les données ne sont pas compatibles avec une moyenne égale à 12.




*La p-valeur est la probabilité, si $H_0$ était vraie, d'observer un écart au moins aussi grand. Elle ne mesure pas la probabilité que $H_0$ soit vraie.*

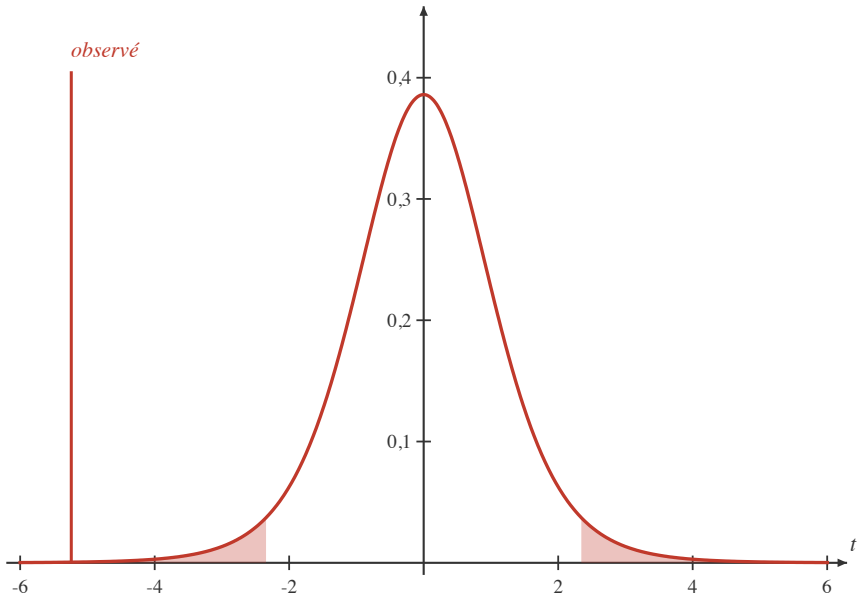
### 3.8.3 - Comparer deux moyennes

Deux méthodes de dosage appliquées à des échantillons différents. Le test de Welch ne suppose pas les variances égales.

Test de Welch, Student à variances inégales. $H_0 : \mu_1 = \mu_2$ ; $H_1 : \mu_1 \neq \mu_2$.

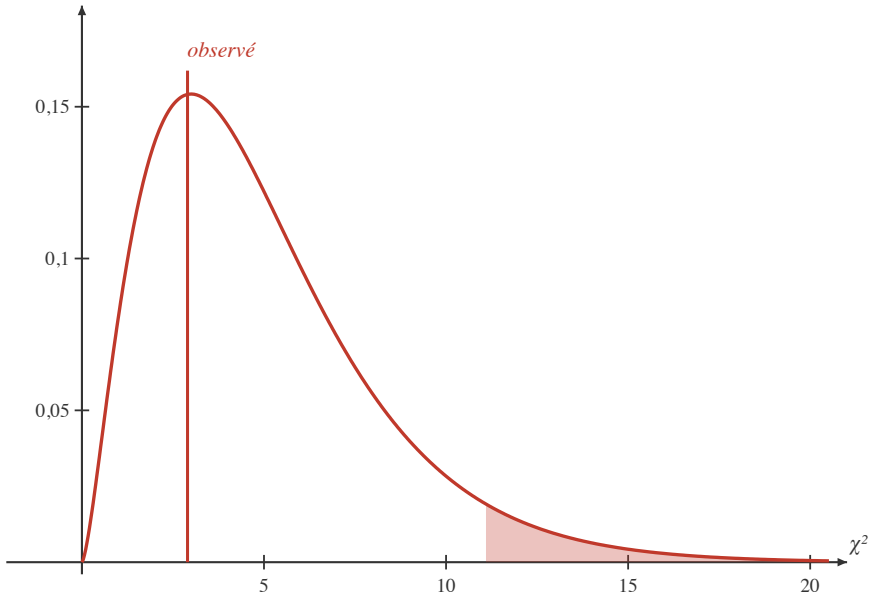
Moyennes $\bar{x}_1 = 20{,}92$ et $\bar{x}_2 = 23{,}87$ ; statistique $t \approx -5{,}24$, $7{,}584$ degrés de liberté ; p-valeur $p \approx 0{,}0009291$.

Au seuil de $5\,\%$ : $p < 0{,}05$, on rejette $H_0$ — les données ne sont pas compatibles avec l'égalité des moyennes.




### 3.8.4 - Un dé est-il équilibré ?

Test du $\chi^2$ d'adéquation. $H_0$ : les effectifs observés suivent la répartition théorique.
Statistique $\chi^2 \approx 2{,}9$, 5 degrés de liberté ; p-valeur $p \approx 0{,}7154$.
Au seuil de $5\,\%$ : $p \geqslant 0{,}05$, on ne rejette pas $H_0$ — les données sont compatibles avec la répartition théorique.



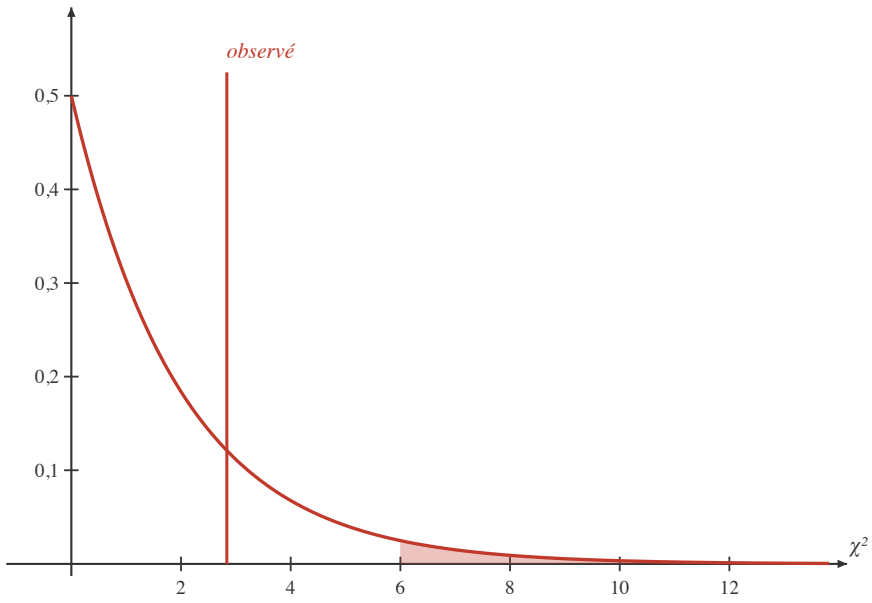
### 3.8.5 - Deux caractères sont-ils indépendants ?

Choix d'une option selon la filière, en effectifs :

Test du $\chi^2$ d'indépendance sur un tableau $2 \times 3$. $H_0$ : les deux caractères sont indépendants.

Statistique $\chi^2 \approx 2{,}835$, 2 degrés de liberté ; p-valeur $p \approx 0{,}2423$.

Au seuil de $5\,\%$ : $p \geqslant 0{,}05$, on ne rejette pas $H_0$ — les données sont compatibles avec l'indépendance.




<>Les données sont-elles normales ?

Le test de Student suppose des données issues d'une loi normale ; le test de Shapiro-Wilk le vérifie.

Test de normalité de Shapiro-Wilk sur $n = 8$ valeurs. $H_0$ : la série est issue d'une loi normale.

Statistique $W \approx 0{,}9721$ ; p-valeur $p \approx 0{,}9137$.

Au seuil de $5\,\%$ : $p \geqslant 0{,}05$, on ne rejette pas $H_0$ — les données sont compatibles avec une loi normale.

*Ne pas rejeter la normalité n'est pas la démontrer : sur huit valeurs, le test a peu de puissance.*

# 3.9 - Analyse de données : la classification

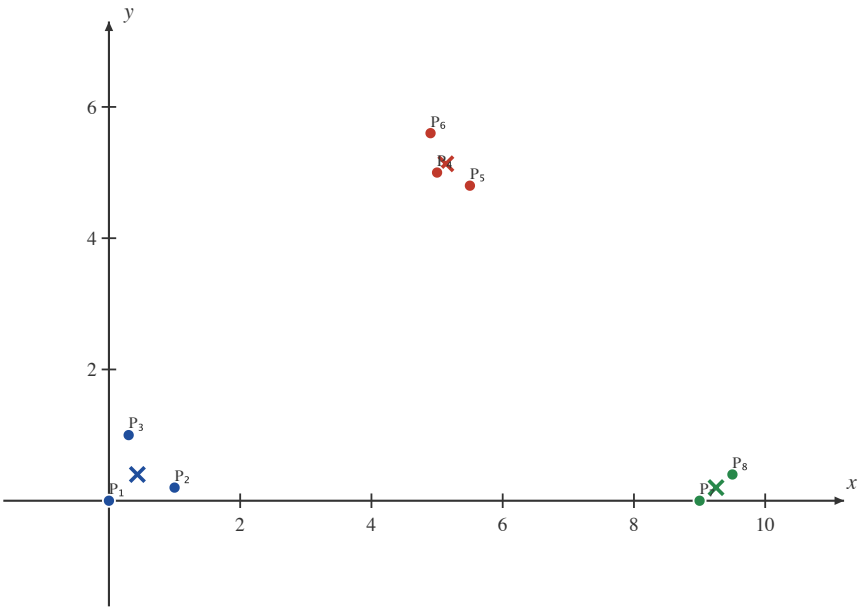
Regrouper des individus semblables sans classes connues d'avance : c'est la classification non supervisée. docdg la conduit par les k-moyennes et par la classification ascendante hiérarchique.

## *3.9.1 - Les k-moyennes*

On fixe le nombre de groupes ; l'algorithme alterne l'affectation de chaque point au centre le plus proche et le recalcul des centres, jusqu'à stabilité.

Partition en 3 groupes par les k-moyennes (initialisation k-means++, graine fixe : le document est reproductible) — groupe 1 : $P_1$, $P_2$, $P_3$ (centre $(0{,}4333\,;\,0{,}4)$) ; groupe 2 : $P_4$, $P_5$, $P_6$ (centre $(5{,}133\,;\,5{,}133)$) ; groupe 3 : $P_7$, $P_8$ (centre $(9{,}25\,;\,0{,}2)$).

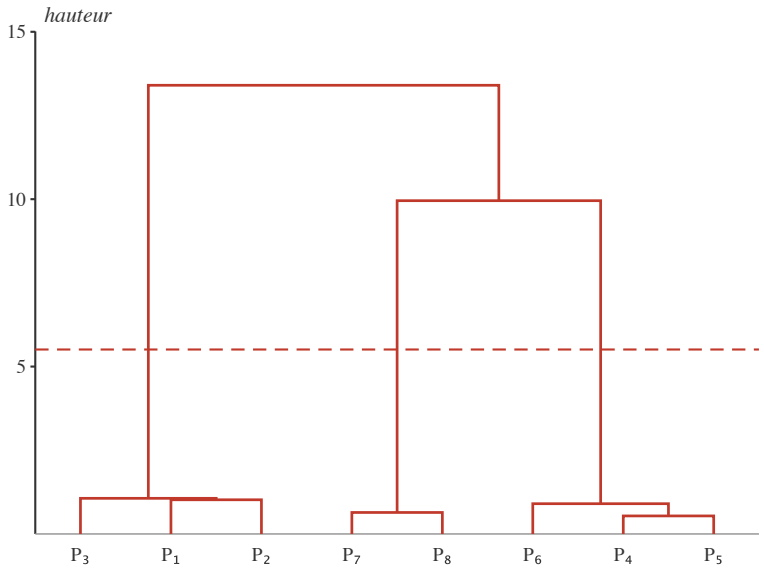
Inertie intra-classe, somme des carrés des distances aux centres : $\approx 1{,}845$.




## *3.9.2 - La classification ascendante hiérarchique*

On part d'autant de groupes que de points, et l'on fusionne à chaque étape les deux groupes dont l'union augmente le moins l'inertie (critère de Ward). Le dendrogramme garde la trace des fusions ; le couper à une hauteur donne une partition.

Classification ascendante hiérarchique des 8 points, critère de Ward : le dendrogramme fusionne d'abord les groupes les plus proches ; la hauteur d'une fusion mesure l'augmentation d'inertie qu'elle coûte. Coupé en 3 groupes : $\{P_1, P_2, P_3\}$, $\{P_4, P_5, P_6\}$, $\{P_7, P_8\}$.




*Les deux méthodes retrouvent ici les mêmes groupes ; la grande hauteur de la dernière fusion signale une partition bien marquée.*

## 3.10 - Autant de dés que l'on veut

Pour n = 3, on représente la somme de trois dés :

